Predição e explicabilidade da intensidade de reutilização de Agent Skills entre repositórios do GitHub*

Pedro Odorize[1]

Instituto de Informática – Universidade Federal do Rio Grande do Sul (UFRGS)
Porto Alegre, RS – Brasil

pedro.odorize@inf.ufrgs.br

Abstract.
Este trabalho investiga a intensidade de reutilização de *Agent Skills*, definida como o número de repositórios que contêm o mesmo `SKILL.md`, entre conteúdos observados em pelo menos dois repositórios. A partir de 200.000 conteúdos do GitSkills, 25.918 skills reutilizadas compõem o desenvolvimento e 6.479 o teste externo, separados por repositório representativo. Com três dobras agrupadas, comparamos as visões *skill-only*, *repository-only* e *hybrid* com Ridge; em experimento distinto, comparamos seis regressores usando apenas atributos de repositório. O Random Forest foi escolhido pelo menor RMSLE médio na validação agrupada (0,575 ś 0,008) e alcançou 0,583 no teste, frente a 0,714 de uma referência que prediz a mediana do desenvolvimento. Contudo, seu MAE externo (3,266) superou o da referência (3,067), e todas as 324 skills acima do P95 do treino foram subestimadas. A comparação de representações sugere sinal nos atributos da skill, mas sua diferença entre visões é pequena e não possui avaliação externa. As importâncias por permutação apontam variáveis contextuais, como linguagem e histórico, com variação entre dobras; não estabelecem efeitos causais nem qualidade da skill. O estudo oferece um pipeline auditável e delimita onde a previsão e as explicações são úteis ou insuficientes.

Palavras-chave: Agent Skills; reúso de software; mineração de repositórios; regressão; explicabilidade.

1 Introdução

1.1 Contexto e motivação

A adoção de agentes baseados em Grandes Modelos de Linguagem (LLMs) na engenharia de software vem sendo acompanhada pelo surgimento de novos artefatos destinados a encapsular conhecimento operacional. Entre eles estão as *Agent Skills*: diretórios portáveis que combinam metadados estruturados, instruções em linguagem natural e, eventualmente, scripts, referências e outros recursos. O arquivo `SKILL.md` funciona como

*Dados e código: `https://github.com/podorize/skillreuse`.

o núcleo descritivo desse artefato, orientando o agente sobre como executar uma tarefa, quais restrições observar e quais recursos utilizar [Agent Skills]. Dessa forma, as skills ampliam a noção tradicional de reúso de software, pois permitem distribuir procedimentos e conhecimento de domínio sem depender exclusivamente de código executável ou de uma biblioteca com uma interface formal.

O reúso de software é estudado há décadas como mecanismo para reduzir esforço de implementação, disseminar soluções e aumentar a produtividade dos desenvolvedores [Haefliger et al. 2008, Lopes et al. 2017]. Entretanto, a disseminação de Agent Skills apresenta características próprias. Parte relevante do comportamento do artefato é expressa em linguagem natural e interpretada por um LLM, enquanto sua distribuição ocorre em repositórios que podem possuir convenções, públicos e mecanismos de publicação distintos. Uma skill pode ser reutilizada porque sua especificação é clara e portável, mas também pode aparecer em vários repositórios por estar associada a um template, a um projeto popular ou a um processo automatizado de cópia. Essas possibilidades misturam propriedades do artefato e do contexto de distribuição, dificultando a interpretação da reutilização observada.

Estudos recentes começaram a caracterizar esse ecossistema. O GitSkills disponibiliza um corpus em larga escala de ocorrências de skills, seus conteúdos e metadados de repositórios [Destefanis et al. 2027]. Outras pesquisas examinam defeitos de especificação e empacotamento [Zhang et al. 2026], o efeito da inclusão de skills em tarefas de engenharia de software [Han et al. 2026] e a evolução de prompts em aplicações baseadas em LLMs [Tafreshipour et al. 2025]. Esses trabalhos fornecem bases importantes para compreender a construção, a qualidade e a utilidade de artefatos instrucionais, mas ainda há espaço para estudar uma questão complementar: quais características estão associadas à intensidade com que uma skill é replicada entre repositórios?

Essa questão é relevante sob duas perspectivas. Para a autoria, evidências empíricas podem indicar quais propriedades estruturais e instrucionais merecem ser investigadas em ferramentas de apoio à criação e validação de skills. Para o ecossistema, a análise pode esclarecer se a disseminação observada contém sinal associado ao conteúdo da skill, ao repositório que a hospeda ou à combinação de ambos. A distinção é importante porque uma associação preditiva não implica que uma característica cause a reutilização, nem que a skill seja funcionalmente superior, mais útil ou adotada de forma independente.

1.2 Problema de pesquisa

Neste trabalho, operacionalizamos a reutilização como a presença de conteúdo idêntico de `SKILL.md` em múltiplos repositórios. Cada conteúdo distinto é identificado por `content_hash`, e a intensidade de reutilização é medida pelo número de repositórios distintos que contêm esse conteúdo. O alvo principal é, portanto, uma contagem condicional às skills reutilizadas (`reused = 1`). Essa escolha permite investigar diretamente a escala observada de disseminação, ao mesmo tempo em que reconhece as limitações da medida: cópia exata não revela a intenção do desenvolvedor, não captura versões modificadas ou semanticamente equivalentes e não mede qualidade ou sucesso de execução.

Para investigar o problema, construímos um pipeline reprodutível de aprendizado de máquina. O pipeline combina atributos estruturais da skill, características textuais

extraídas por TF-IDF e variáveis contextuais do repositório. A avaliação utiliza divisão agrupada por `representative_repo_id`, de modo a evitar que o mesmo grupo de dependência apareça em treino e avaliação. Vocabulário, transformação, seleção de atributos e demais etapas ajustáveis são realizados dentro das dobras de validação, reduzindo o risco de vazamento de informação [Kaufman et al. 2012, Roberts et al. 2017]. Como o alvo tem cauda longa, o desempenho é analisado por RMSLE, MAE, correlação de Spearman e faixas de intensidade.

O estudo compara as representações *skill-only*, *repository-only* e *hybrid* com Ridge nas mesmas dobras. Um benchmark distinto compara seis regressores com os mesmos atributos `repository-only`. A interpretação reúne indícios textuais exploratórios e importância e cenários de previsão para o Random Forest de repositório. Essas explicações são hipóteses dependentes do modelo, não efeitos causais. Modelos podem explorar padrões incidentais que refletem origem e visibilidade dos repositórios [Geirhos et al. 2020, Lapuschkin et al. 2019].

1.3 Objetivos e perguntas de pesquisa

O objetivo geral é investigar, de forma reprodutível e interpretável, quais características observáveis estão associadas à intensidade de reutilização de Agent Skills entre repositórios.

Os objetivos específicos são:

1. construir um pipeline de regressão com controle explícito de vazamento;
2. comparar modelos e representações de atributos sob validação agrupada;
3. analisar o desempenho na região central e na cauda da distribuição de reutilização; e
4. examinar a consistência das associações nas dobras disponíveis e interpretar seus limites.

O trabalho busca responder às seguintes perguntas de pesquisa:

- **RQ1 — Previsibilidade da intensidade:** em que medida características textuais, estruturais e contextuais permitem prever o número de repositórios que reutilizam uma skill?
- **RQ2 — Origem do sinal preditivo:** qual é a contribuição relativa das características da skill, do contexto do repositório e da combinação entre ambos para a previsão da intensidade?
- **RQ3 — Explicabilidade e limites:** quais variáveis se associam às previsões, com que consistência entre dobras, e quais são os limites dessas associações diante da cauda e dos sinais contextuais?

1.4 Contribuições

As contribuições são: (i) um pipeline reprodutível com controle explícito de vazamento para estudar a intensidade condicional de replicação; (ii) uma comparação crítica de modelos e representações, relacionando desempenho a seus vieses e às características dos

dados; e (iii) uma auditoria da região central e da cauda, acompanhada de interpretações cautelosas dos atributos. Os resultados são evidência observacional de um snapshot do GitHub, não demonstração de causalidade, qualidade intrínseca ou adoção futura.

Em termos concretos, o trabalho contribui com:

1. um protocolo leakage-aware para modelar intensidade de reutilização condicional;
2. um benchmark comparativo de modelos lineares, vizinhança, árvores e ensembles;
3. uma análise das diferenças entre atributos da skill, contexto do repositório e representação híbrida; e
4. uma avaliação cautelosa da importância dos atributos do repositório e de indícios textuais exploratórios, com limites de interpretação explícitos.

1.5 Organização do trabalho

O restante do relatório está organizado da seguinte forma. A Seção 2 apresenta os trabalhos relacionados. A Seção 3 descreve os dados, o pré-processamento, os modelos e a validação. A Seção 4 apresenta os resultados. A Seção 5 discute o desempenho, a explicabilidade e as ameaças à validade. A Seção 6 apresenta as conclusões e os trabalhos futuros.

2 Trabalhos relacionados

2.1 Reúso de software, clonagem e artefatos em linguagem natural

O reúso de software é uma prática central da engenharia de software e tem sido estudado tanto pela perspectiva da adoção de componentes quanto pela disseminação de soluções em ecossistemas de código aberto. Estudos sobre desenvolvimento aberto analisam como componentes e práticas são compartilhados entre projetos [Mockus et al. 2002, Haefliger et al. 2008], enquanto trabalhos sobre clonagem investigam a presença de conteúdos duplicados em larga escala no GitHub [Lopes et al. 2017]. A literatura também mostra que o reúso em projetos abertos pode ocorrer por diferentes mecanismos, incluindo dependências formais, cópia de componentes, templates e processos de integração pouco padronizados [Heinemann et al. 2011].

Esses trabalhos oferecem uma base importante para estudar a disseminação de artefatos, mas concentram-se predominantemente em código executável, interfaces formais, pacotes e dependências. Agent Skills introduzem uma extensão relevante desse cenário: seu comportamento operacional é especificado em linguagem natural, ainda que o artefato possa conter metadados, scripts e recursos estruturados. A cópia de uma skill entre repositórios é, portanto, semelhante à replicação de outros artefatos textuais, mas não é equivalente à reutilização de uma biblioteca. Ela não informa se o conteúdo foi executado, se foi adaptado às necessidades do projeto ou se sua inclusão resultou de uma decisão independente de adoção.

Nosso estudo se aproxima da literatura de clonagem ao identificar conteúdos idênticos por hash e contar os repositórios distintos em que aparecem. A diferença é que o objeto de análise não é um fragmento arbitrário de código, mas uma unidade documental e

operacional (`SKILL.md`). Essa escolha permite medir a disseminação exata do artefato, mas exclui cópias modificadas, equivalência semântica e transferência parcial de conhecimento. Por isso, utilizamos os termos *replicação* e *intensidade de reutilização* de forma operacional, sem tratá-los como medidas diretas de qualidade, utilidade ou adoção.

2.2 Agent Skills, artefatos de prompt e utilidade funcional

Pesquisas sobre modelos de linguagem com uso de ferramentas estudam seleção de ferramentas, planejamento e execução de chamadas durante a inferência [Schick et al. 2023, Shen et al. 2023, Yao et al. 2023, Qin et al. 2023]. Esses protocolos são relacionados ao problema de comportamento de agentes, mas diferem do objeto deste trabalho. Enquanto um protocolo de uso de ferramentas descreve como um modelo decide ou executa uma chamada, uma Agent Skill é um artefato persistente, hospedado em um repositório, que descreve procedimentos, restrições e convenções para orientar o agente em diferentes tarefas [Agent Skills].

Estudos recentes passaram a investigar propriedades específicas de skills e prompts em repositórios. O GitSkills fornece um corpus em larga escala com conteúdos, ocorrências e metadados de repositórios [Destefanis et al. 2027]. Zhang et al. analisam defeitos de especificação e empacotamento e relacionam metadados de roteamento à recuperação de skills [Zhang et al. 2026]. Han et al. avaliam se a inclusão de skills melhora o desempenho de agentes em tarefas reais de engenharia de software [Han et al. 2026]. Tafreshipour et al. estudam a evolução de prompts em aplicações de software, concentrando-se em mudanças temporais e práticas de manutenção [Tafreshipour et al. 2025].

Essas linhas de pesquisa cobrem construção de corpus, conformidade estrutural, evolução de instruções e utilidade downstream. Contudo, elas não respondem diretamente se características observáveis de uma skill estão associadas à quantidade de repositórios que reproduzem seu conteúdo. A presente pesquisa complementa esses estudos ao tratar a disseminação entre repositórios como um desfecho observável e ao separar características intrínsecas da skill de atributos do contexto hospedeiro. Essa distinção também evita uma inferência indevida: uma skill pode ser replicada em muitos repositórios por razões de distribuição ou popularidade, sem necessariamente apresentar melhor desempenho funcional.

2.3 Aprendizado de máquina em engenharia de software e avaliação fora da amostra

Aprendizado de máquina é utilizado em engenharia de software para apoiar tarefas como previsão de defeitos, classificação de artefatos, recomendação e análise de repositórios. Esses estudos demonstram o valor de combinar atributos estruturais, textuais e contextuais, mas também evidenciam que o desempenho pode variar substancialmente conforme a divisão dos dados, a disponibilidade de metadados e o tipo de generalização pretendida [Menzies et al. 2010].

Um risco particularmente importante é o vazamento de informação. Quando observações relacionadas ao mesmo projeto, organização ou entidade aparecem simultaneamente no treinamento e na avaliação, o modelo pode memorizar características do grupo

em vez de aprender relações que generalizem para novos projetos [Kaufman et al. 2012]. A literatura de validação estruturada recomenda agrupar unidades dependentes durante a validação cruzada, especialmente quando os dados possuem estrutura hierárquica, temporal ou espacial [Saeb et al. 2017, Roberts et al. 2017]. No contexto de repositórios, isso é relevante porque várias skills podem compartilhar metadados, convenções de diretório e sinais de popularidade.

Outro problema é o aprendizado de atalhos: modelos podem explorar regularidades incidentais que produzem bom desempenho na avaliação, mas não representam o fenômeno de interesse [Geirhos et al. 2020, Lapuschkin et al. 2019]. Por essa razão, a pesquisa usa divisão agrupada por `representative_repo_id`, refaz as etapas ajustáveis dentro das dobras e seleciona candidatos sem consultar o teste externo. O agrupamento oferece uma definição mais restrita de generalização para grupos de repositórios não observados, mas não separa necessariamente organizações ou redes de cópias.

2.4 Regressão, explicabilidade e lacuna da pesquisa

Uma formulação binária como reutilizado versus não reutilizado descarta a escala de disseminação. Nesta pesquisa, a intensidade é uma contagem condicional às skills reutilizadas. A EDA mostrou assimetria positiva e sobredispersão; por isso, os seis regressores são treinados com `log1p(repository_count)` e avaliados por RMSLE, MAE, Spearman e erro por faixa. Essa formulação permite distinguir o desempenho na região central e na cauda de alta reutilização.

A explicabilidade descreve como o modelo combina atributos; ela não converte associações preditivas em efeitos causais. Importância por permutação e análise de cenários ajudam a investigar variáveis relevantes, mas dependem do modelo e da distribuição de validação. Variáveis correlacionadas podem compartilhar importância; cenários fora da distribuição observada podem ser pouco confiáveis. A distinção entre explicar previsões e explicar o fenômeno é central [Molnar 2020, Shmueli 2010, Breiman 2001].

Os trabalhos citados motivam a análise da intensidade de replicação exata como desfecho distinto da qualidade funcional. Nosso estudo compara sinais da skill e do repositório com Ridge, compara seis famílias sobre atributos de repositório e audita seus erros e explicações. Essa combinação delimita uma contribuição empírica para o corpus analisado, sem pretensão de estabelecer uma lacuna exaustiva na literatura ou demonstrar causalidade.

3 Metodologia

3.1 Desenho da pesquisa

Este estudo adota um desenho empírico quantitativo, preditivo e interpretável. O objetivo não é estimar um efeito causal da forma de escrever uma skill sobre sua reutilização, mas investigar se características observáveis contêm informação preditiva sobre a intensidade de sua replicação entre repositórios. Essa distinção segue a separação entre explicação e previsão proposta na literatura de modelagem estatística [Shmueli 2010].

O pipeline compara três representações com Ridge nas mesmas dobras agrupadas

e, em experimento distinto, seis regressores sob a representação `repository-only`. Vocabulário, seleção de termos, imputação e codificação são ajustados dentro das dobras. Hiperparâmetros e candidatos ao teste foram escolhidos pelos resultados de validação do desenvolvimento. O teste externo foi consultado uma vez para estimar o desempenho dos dois candidatos congelados; suas previsões salvas são usadas depois apenas para análise descritiva.

3.2 Dados e unidade de análise

A fonte é o corpus público GitSkills, revisão `ebab17454a7c236f8f26b183567f1a126f42e3f8` [Destefanis et al. 2027]. A amostra contém 200.000 conteúdos distintos selecionados deterministicamente pela ordenação `md5(content_hash || ':20261009')`. A unidade de análise é um conteúdo único de `SKILL.md`, identificado por `content_hash`.

A deduplicação ocorre antes da divisão dos dados. Assim, quando o mesmo conteúdo aparece em vários repositórios, ele contribui com uma única observação analítica. O número de repositórios distintos em que o conteúdo aparece é calculado sobre todas as ocorrências disponíveis e utilizado exclusivamente para definir o alvo. Identificadores, contagens derivadas do alvo e atributos que revelam diretamente a atribuição de treino ou teste não são utilizados como preditores.

Cada conteúdo possui um `representative_repo_id`, utilizado como grupo de dependência. Esse identificador representa o contexto de repositório disponível na tabela de atributos e não garante, por si só, a separação de todos os repositórios relacionados ou de todas as cópias quase idênticas. Essa limitação é considerada na interpretação da generalização.

3.3 Definição do alvo

O alvo principal é `repository_count`, definido como o número de repositórios distintos que contêm exatamente o mesmo conteúdo de `SKILL.md`. A modelagem é condicional a `reused = 1`, isto é, considera apenas conteúdos presentes em pelo menos dois repositórios. Dessa forma, a pergunta operacional é:

> Entre as skills reutilizadas, em que medida as características observadas permitem prever quantos repositórios as reutilizam?

A escala de contagem é preservada como desfecho principal. Utiliza-se `log1p(repository_count)` durante o treinamento dos regressores e realiza-se a transformação inversa para a avaliação na escala original. Os estratos derivados da contagem são usados somente para compor as partições agrupadas; não são preditores nem alvos dos modelos.

A análise exploratória mostrou forte assimetria positiva e sobredispersão: a média do alvo é aproximadamente 5,08, a mediana é 2, a variância é aproximadamente 112,22 e a razão variância/média é aproximadamente 22,11. Esses resultados motivam o treinamento na escala `log1p` e a avaliação tanto do erro global quanto dos erros na cauda da distribuição.

3.4 Divisão dos dados e controle de dependência

A avaliação tem duas camadas. A partição externa separa 160.000 conteúdos para desenvolvimento e 40.000 para teste, com grupos de `representative_repo_id` disjuntos. Após condicionar a `reused = 1`, restam 25.918 e 6.479 observações, respectivamente. O teste externo não participou da seleção de atributos, algoritmos ou hiperparâmetros. Os dois resultados externos já obtidos são apresentados integralmente.

Segundo, o conjunto de desenvolvimento é avaliado por validação cruzada agrupada, atualmente com três dobras. O agrupamento impede que observações pertencentes ao mesmo `representative_repo_id` apareçam simultaneamente no treino e na validação de uma dobra. A estratificação é utilizada para manter, tanto quanto possível, a distribuição do alvo e dos estratos de reutilização entre as dobras. Essa estratégia segue a recomendação de separar amostras relacionadas em problemas com estrutura hierárquica [Saeb et al. 2017, Roberts et al. 2017].

Em cada dobra, todas as operações ajustáveis são aprendidas somente no subconjunto de treino: imputação, escalonamento, codificação categórica, vocabulário TF-IDF, seleção de termos e ajuste do modelo. Esse procedimento reduz o risco de vazamento de informação e evita que a validação influencie diretamente a construção das variáveis [Kaufman et al. 2012].

3.5 Construção das variáveis

As variáveis são organizadas em três blocos:

1. **Atributos da skill:** medidas de comprimento e diversidade lexical, estrutura Markdown, front matter, localização, nome de arquivo e presença de scripts, referências e arquivos relacionados.
2. **Atributos textuais:** unigramas e bigramas do conteúdo de `SKILL.md`, representados por TF-IDF com frequência de termo sublinear.
3. **Atributos do repositório:** linguagem, licença, estrelas, forks, commits, estado de fork e indicadores de coleta de metadados e histórico. A localização da skill pertence ao bloco estrutural.

Valores ausentes categóricos recebem uma categoria explícita. Valores numéricos são imputados pela mediana aprendida no treino da dobra, com indicadores para colunas com ausência, e depois escalonados. A ausência de histórico é interpretada como falta de coleta, não como ausência de atividade. `content_hash`, `representative_repo_id`, `repository_count`, `occurrence_count`, `reused`, `reuse_intensity`, estrato e partição são excluídos dos preditores.

Não foi aplicado corte ou winsorização às contagens altas: elas permanecem no alvo e são auditadas separadamente. `repo_metadata_fetched` assumiu um único valor no subconjunto reutilizado do desenvolvimento, mas permaneceu no conjunto congelado de atributos. Como não discrimina essas observações, sua importância por permutação é zero; removê-lo após consultar o teste alteraria o pipeline avaliado. Essa escolha é registrada como limitação de pré-processamento.

3.6 Representação textual e seleção de atributos

O vocabulário textual é reconstruído em cada dobra. A exploração comparou pools de 5.000, 10.000 e 20.000 candidatos TF-IDF e limites de 50, 100, 200 e 500 termos. Para o alvo contínuo, a triagem univariada utiliza `f_regression` sobre `log1p(repository_count)`, ajustada somente no treino da dobra.

Esse procedimento é uma etapa de seleção de atributos, mas não constitui vazamento quando é ajustado exclusivamente com os dados de treinamento da dobra. A validação serve para comparar configurações sem permitir que os rótulos da dobra de validação influenciem a seleção. O pool histórico de 211 termos não participa do novo pipeline.

São comparadas três visões de atributos:

- **skill-only:** atributos estruturais e textuais da skill;
- **repository-only:** atributos contextuais do repositório;
- **hybrid:** combinação dos blocos da skill e do repositório.

A configuração de 10.000 candidatos e 500 termos foi usada na comparação final das três visões com Ridge. Não há avaliação externa dessa configuração textual.

3.7 Modelos avaliados

O protocolo utiliza regressão para prever a contagem de reutilização. Os seis regressores comparados são Ridge, KNN, árvore de decisão, Random Forest, Gradient Boosting e HistGradientBoosting, todos treinados sobre `log1p(repository_count)`. As previsões são transformadas de volta à escala original para avaliação.

O benchmark compara os seis vieses indutivos sob as mesmas dobras e atributos. O critério principal de seleção é o menor RMSLE médio na validação agrupada. Random Forest e Gradient Boosting foram levados ao teste externo para documentar também o compromisso entre RMSLE e MAE; os dois resultados são apresentados sem seleção retroativa pelo teste.

Para comparar todas as famílias nas 25.918 observações reutilizadas do desenvolvimento, o benchmark completo utiliza a visão `repository-only`. As visões híbrida e `skill-only` foram avaliadas com Ridge em experimento distinto. Esses resultados não constituem uma comparação das seis famílias sobre texto e estrutura.

3.8 Métricas e análise de erros

A métrica principal é o RMSLE, calculado como:

$$\mathrm{RMSLE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left[\log(1+y_i) - \log(1+\hat{y}_i)\right]^2}.$$

O RMSLE reduz a influência de valores extremos e avalia o erro na escala logarítmica. As métricas secundárias são MAE na escala original, MAE na escala logarítmica e correlação de Spearman. Previsões negativas após a transformação inversa são truncadas em zero para o cálculo das métricas. Uma referência constante prediz a mediana do alvo do desenvolvimento.

Além das médias agregadas, os erros são analisados por quantis do alvo. Na auditoria de validação do Ridge híbrido, os cortes são calculados no treino de cada dobra. Na auditoria descritiva do Random Forest no teste, os cortes são calculados em todo o desenvolvimento (P50=2, P75=4, P90=8 e P95=16). São reportados RMSLE, MAE, erro mediano assinado e proporção de subestimação por faixa.

3.9 Explicabilidade

A análise textual explora termos recorrentes e a robustez ao mascaramento de artefatos. Para o Random Forest `repository-only`, a importância por impureza do ajuste final é complementada por permutação de cada atributo bruto em três dobras agrupadas do desenvolvimento, com uma permutação por atributo e dobra. Um cenário de previsão varia `repo_stars` em uma amostra da primeira dobra, mantendo os outros atributos fixos. O cenário descreve a resposta do modelo e não estima efeito causal.

Termos correlacionados podem compartilhar atribuições; estrelas, forks e histórico também podem atuar como proxies da origem ou visibilidade. A estabilidade é avaliada pelas três dobras, sem extrapolar a conclusão para outras amostras. As explicações são associações dependentes do modelo, não regras causais de autoria ou evidência de qualidade.

3.10 Reprodutibilidade

Os manifestos registram a revisão dos dados, assinaturas da amostra e da divisão, sementes, configurações principais, cardinalidades e métricas. As tabelas por dobra e o código documentam o restante dos cálculos. O Apêndice A fornece os comandos e relaciona cada tabela e figura do relatório ao artefato que a originou. Isso permite repetir a validação e auditar os números apresentados, sujeito à disponibilidade do snapshot público e dos recursos computacionais necessários.

O pipeline também documenta as limitações conhecidas: o agrupamento por repositório representativo não elimina todas as relações entre repositórios, a replicação exata não captura cópias modificadas e o teste externo representa um snapshot específico do ecossistema GitHub. Essas limitações são incorporadas à análise de validade e à interpretação dos resultados.

4 Resultados

4.1 Caracterização do alvo e dos dados

Esta seção apresenta os resultados consolidados do estudo para a disciplina. O benchmark comparativo foi realizado por validação cruzada agrupada e a avaliação externa foi

executada uma vez após o congelamento dos candidatos na visão `repository-only`. Os resultados das visões textuais são apresentados em análises separadas.

Entre as skills reutilizadas, `repository_count` apresenta distribuição fortemente assimétrica e sobredispersa. A média é 5,075 repositórios, a mediana é 2, a variância é 112,22 e a razão entre variância e média é 22,11. O maior valor observado no conjunto de desenvolvimento é 390 repositórios. A diferença entre média e mediana indica que poucas skills concentram valores muito elevados.

Os quantis do desenvolvimento, calculados somente nas 25.918 skills reutilizadas, são:

Quantil	P50	P75	P90	P95	P99
Repositórios	2	4	8	16	55

A figura abaixo mostra a concentração nos valores baixos e a cauda longa. No teste, o maior valor observado é 573. A transformação `log1p` estabiliza o ajuste, mas o resultado agregado deve ser lido junto com o erro na cauda.

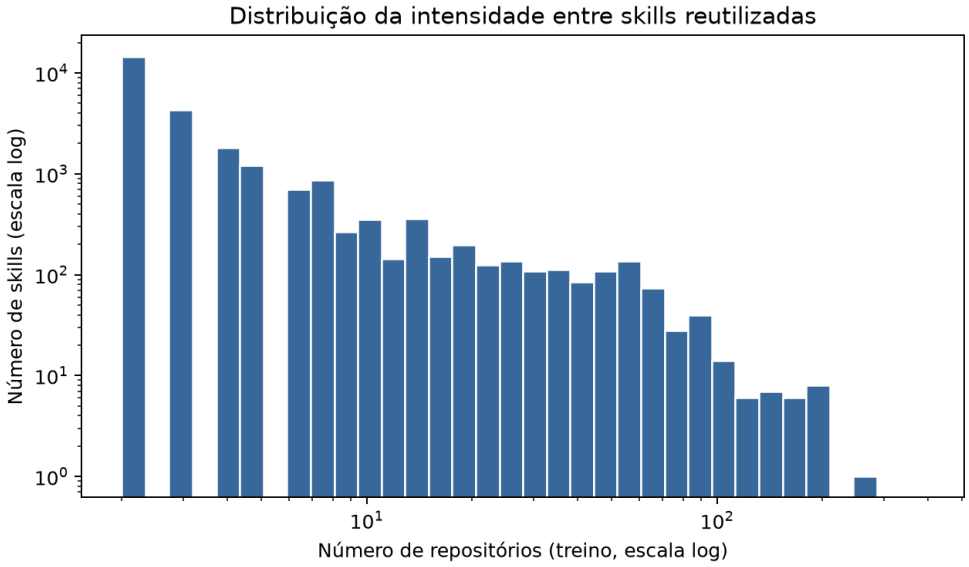


Figura 1: Distribuição do alvo no desenvolvimento

Nos atributos de repositório do desenvolvimento, `commit_count` está ausente em 69,86% das 25.918 observações; estrelas, forks, linguagem, licença e estado de fork têm aproximadamente 0,035% de ausência cada. `history_fetched` e `repo_metadata_fetched` não têm valores ausentes, mas sinalizam a cobertura da coleta. A imputação e os indicadores de ausência foram ajustados dentro de cada dobra. A tabela auditável está em `repository_missingness.csv`.

4.2 Comparação das representações

A confirmação completa da configuração textual atual foi realizada com 10.000 candidatos TF-IDF e 500 termos selecionados, utilizando regressão Ridge sobre

`log1p(repository_count)` e três dobras agrupadas. A representação híbrida apresentou o menor RMSLE entre as três visões avaliadas, embora a diferença para *skill-only* seja pequena.

Representação com Ridge	RMSLE médio ś DP	MAE médio	Spearman médio
`hybrid`	**0,568 ś 0,028**	3,320	0,245
`skill-only`	0,572 ś 0,031	3,325	0,213
`repository-only`	0,588 ś 0,006	3,341	0,259

Os resultados sugerem sinal nos atributos textuais e estruturais da skill. A diferença média entre `hybrid` e `skill-only` é de apenas 0,004 no RMSLE, menor que a variação entre dobras; não se pode afirmar uma superioridade robusta do híbrido. `repository-only` apresenta a maior correlação de Spearman nessa comparação, apesar do pior RMSLE. Essas são estimativas de validação interna do Ridge; nenhum dos dois modelos textuais foi avaliado no teste externo.

Essa diferença também reforça a necessidade de interpretar o modelo híbrido com cautela. Parte do sinal pode estar associada ao contexto do repositório, e não a propriedades intrínsecas da skill. Assim, a vantagem híbrida não deve ser descrita como evidência de que o conteúdo da skill, isoladamente, determina maior reutilização.

4.3 Comparação das famílias de modelos

Como parte do trabalho da disciplina, foi executado um benchmark completo com 25.918 observações, três dobras agrupadas e a representação `repository-only`. Essa execução permite comparar todos os regressores sobre a mesma matriz de atributos, sem o gargalo da vetorização textual. Os resultados foram:

Modelo `repository-only`	RMSLE médio ś DP	MAE médio ś DP	Spearman médio
Random Forest	**0,575 ś 0,008**	3,282 ś 0,120	0,287
HistGradientBoosting	0,583 ś 0,019	3,312 ś 0,034	0,255
Gradient Boosting	0,587 ś 0,010	**3,173 ś 0,129**	**0,317**
Ridge	0,588 ś 0,006	3,341 ś 0,156	0,259
Decision Tree	0,593 ś 0,017	3,321 ś 0,073	0,282
KNN	0,610 ś 0,027	3,452 ś 0,054	0,214

O Random Forest apresentou o menor RMSLE, enquanto o Gradient Boosting obteve o menor MAE e a maior correlação de Spearman. Isso mostra que a escolha do melhor modelo depende do critério: o primeiro favorece erro relativo na escala logarítmica, enquanto o segundo produz melhor erro absoluto e ordenação. O resultado também confirma que a árvore isolada e o KNN não oferecem vantagem consistente nessa representação.

Um spot-check agrupado comparou variantes dos dois candidatos. O Random Forest com `max_depth=12`, 100 árvores e `min_samples_leaf=3` teve RMSLE de **0,575 ś 0,008**, contra 0,576 ś 0,008 com 200 árvores e 0,578 ś 0,004 com profundidade 8. O Gradient Boosting com 200 estimadores e taxa 0,05 obteve **0,584 ś 0,008**, ante 0,587 ś 0,010 com 100 estimadores. O critério de escolha principal foi o RMSLE médio da validação agrupada.

O benchmark completo confirma que modelos ensemble não lineares capturam relações úteis na visão `repository-only`, mas não há um vencedor absoluto em todas as métricas. O desempenho de modelos mais flexíveis deve ser interpretado junto com o risco de memorizar padrões contextuais.

Após o congelamento da comparação da disciplina, os dois candidatos selecionados foram treinados em todas as 25.918 observações de desenvolvimento e avaliados uma única vez nas 6.479 skills reutilizadas do teste externo. A sobreposição de `representative_repo_id` foi zero.

Modelo	RMSLE	MAE	MAE log1p	Spearman
Random Forest	**0,5833**	3,2663	0,4063	**0,3667**
Gradient Boosting	0,5907	**3,1820**	**0,3903**	0,2315

O Random Forest já era o candidato principal pelo RMSLE da validação. Os resultados externos estimam o desempenho dos dois candidatos na partição reservada; o teste não redefiniu a escolha. Em comparação com a referência constante que prediz a mediana do desenvolvimento (2 repositórios), o Random Forest reduz o RMSLE de **0,7142** para **0,5833**, mas aumenta o MAE de **3,0665** para **3,2663** e o MAE log1p de 0,3593 para 0,4063. A referência é forte nas métricas médias porque a maior parte do teste tem contagem baixa; o modelo melhora a diferenciação das contagens em RMSLE e Spearman, mas não domina todos os critérios.

4.4 Análise de erros por intensidade de reutilização

Para o Random Forest `repository-only`, as faixas foram definidas pelos quantis do desenvolvimento antes da auditoria das previsões externas salvas. O erro cresce rapidamente acima de oito repositórios:

Faixa observada no teste	n	RMSLE	MAE	Erro mediano (previsto real)	Subestimação
2 (P50)	3.648	0,395	1,33	+1,12	0%
3–4 (P50–P75)	1.522	0,224	0,79	+0,14	41,3%

Faixa observada no teste	n	RMSLE	MAE	Erro mediano (previsto real)	Subestimação
5–8 (P75–P90)	683	0,428	2,22	2,11	90,2%
9–16 (P90–P95)	302	0,925	7,29	7,02	100%
>16 (>P95)	324	1,904	35,15	22,73	100%

Acima do P95, a mediana observada é 27,5 e a mediana prevista é 4,45. Em todo o teste, a maior previsão foi 10,29, frente à maior contagem observada de 573. As figuras mostram a compressão das previsões e o aumento do erro absoluto na cauda.

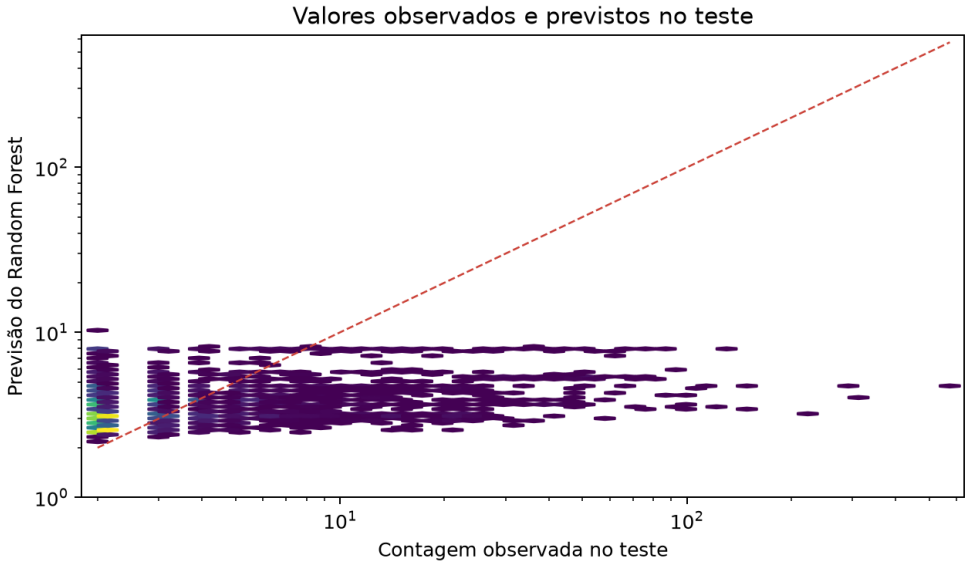


Figura 2: Observado versus previsto no teste externo do Random Forest

Como análise separada, a auditoria por quantis do Ridge híbrido na validação encontrou subestimação crescente. Seus limiares foram calculados no treino de cada dobra e aplicados à validação; não se trata do teste do Random Forest.

Faixa do alvo	Observações	RMSLE	MAE	Subestimação
Até P50	14.593	0,432	1,46	6,7%
P50–P75	6.087	0,302	1,11	48,3%
P75–P90	2.773	0,466	2,25	89,7%
P90–P95	1.232	0,890	7,20	99,7%
Acima de P95	1.233	1,692	34,75	100,0%

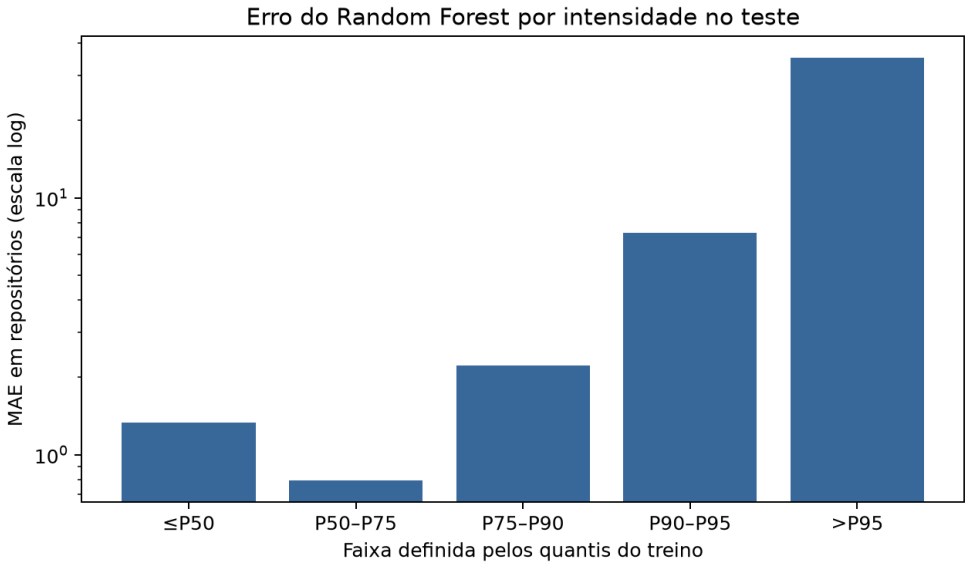


Figura 3: MAE do Random Forest por faixa do alvo

O modelo apresenta desempenho relativamente bom para a região central, mas subestima de forma crescente os valores mais altos. Para as observações acima do P95, a mediana do alvo é 33 repositórios, enquanto a mediana da previsão é aproximadamente 6,22. Portanto, o RMSLE global de 0,568 oculta uma falha importante para o subgrupo mais reutilizado.

Essa auditoria confirma que o Ridge híbrido também não representa adequadamente a disseminação extrema. Os dois resultados de cauda pertencem a modelos, representações e conjuntos de avaliação diferentes e não são uma comparação direta.

4.5 Robustez textual

Foi comparado o texto bruto com uma versão que remove datas, números, URLs e identificadores longos. A remoção desses artefatos alterou pouco o desempenho: no modelo híbrido, o RMSLE passou de 0,568 para 0,570; no modelo `skill-only`, passou de 0,572 para 0,575.

Essa pequena diferença sugere que os artefatos textuais identificados não explicam sozinhos o sinal preditivo global. Entretanto, a análise não permite concluir que todos os termos sejam semanticamente relevantes. A representação textual ainda pode capturar convenções editoriais, templates e padrões de distribuição associados às skills reutilizadas.

4.6 Explicabilidade e consistência

A análise global inicial do modelo híbrido encontrou sete dos 500 termos selecionados com aparência de datas ou números; não foram identificados URLs ou identificadores longos entre os principais termos. Alguns termos recorrentes estavam relacionados a fragmentos editoriais, como `date_added` e `source community`, além de palavras

de conteúdo geral.

A auditoria de estabilidade em três dobras encontrou recorrência de termos editoriais e de convenções de documentação. A versão com artefatos mascarados reduziu os sinais explicitamente numéricos, mas não eliminou termos associados a padrões editoriais. Esses achados devem ser tratados como associações descritivas: a presença de um termo pode indicar um template, uma origem comum ou um processo de publicação, e não necessariamente uma propriedade que cause reutilização.

Na importância por impureza do Random Forest ajustado em todo o desenvolvimento, os maiores valores pertencem a `repo_stars` (0,170), `history_fetched` (0,153), indicador de ausência de `commit_count` (0,132) e `repo_forks` (0,129). Essa medida pode favorecer atributos com mais valores ou categorias. A permutação dos oito atributos brutos na validação agrupada do desenvolvimento fornece um contraste: aumento médio de RMSLE de 0,029 ś 0,013 para `repo_language`, 0,014 ś 0,006 para `commit_count`, 0,013 ś 0,003 para `history_fetched` e 0,012 ś 0,012 para `repo_stars`. Uma das três dobras deu aumento de apenas 0,0005 para estrelas, indicando instabilidade desse sinal. Foi feita uma permutação por atributo e dobra, portanto a incerteza dessa estimativa é limitada.

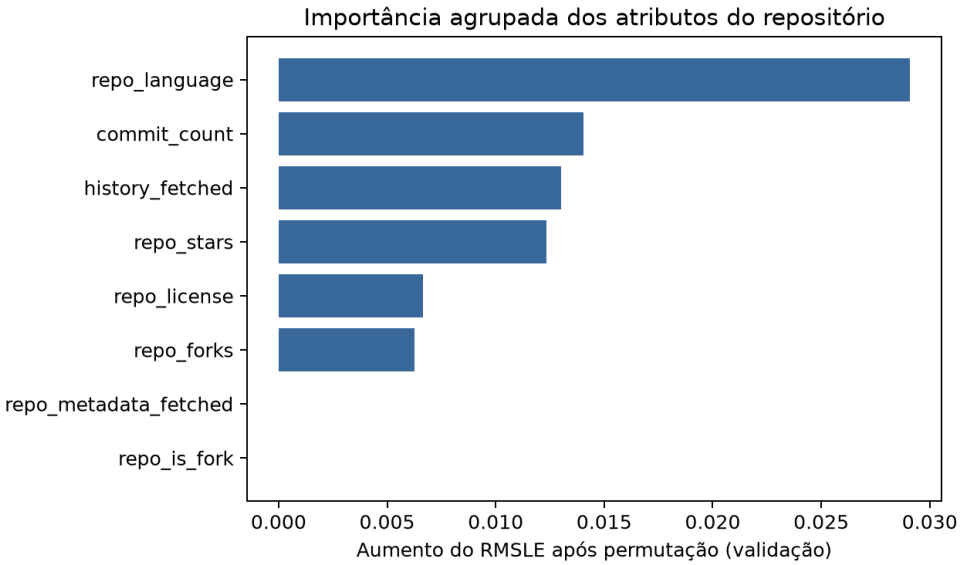


Figura 4: Aumento de RMSLE após permutação em validação agrupada

Um cenário descritivo na primeira dobra variou `repo_stars` para 0, 1, 3, 10, 100 e 1.000 em 1.000 observações de validação, mantendo as outras entradas: a previsão média resultante foi 3,58; 3,62; 3,12; 3,29; 3,22; 3,17 repositórios. A resposta não é monotônica e alguns cenários podem combinar valores incomuns de estrelas e forks. Logo, o experimento não sustenta a afirmação de que aumentar estrelas causaria mais reutilização. Toda essa explicação descreve o contexto do repositório, não propriedades intrínsecas da skill.

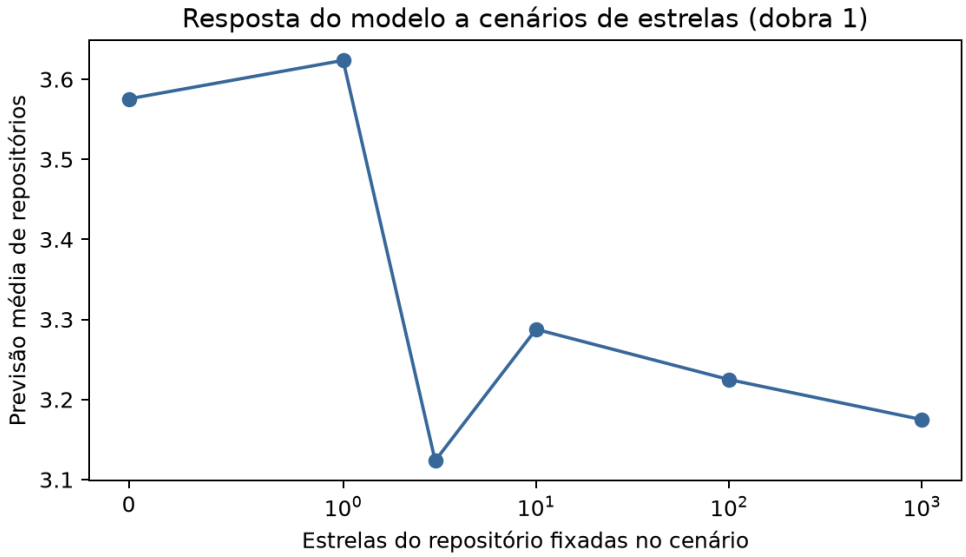


Figura 5: Previsão média ao variar estrelas no primeiro fold

4.7 Síntese dos resultados e estado da avaliação

Os resultados da disciplina sustentam quatro conclusões. Primeiro, existe sinal preditivo mensurável para a intensidade de reutilização, sobretudo na região central da distribuição. Segundo, a representação híbrida apresenta pequena vantagem global no Ridge, mas a comparação completa dos modelos foi realizada de forma controlada na visão `repository-only`. Terceiro, a cauda de alta reutilização continua sendo um problema relevante, com subestimação sistemática dos maiores valores. Quarto, as explicações identificam padrões textuais e contextuais plausíveis, mas não fornecem evidência de causalidade ou de qualidade intrínseca das skills.

O Random Forest foi escolhido na validação pelo menor RMSLE médio e obteve 0,5833 no teste externo. O Gradient Boosting apresentou MAE externo menor (3,1820). Ambos os resultados são descritivos para a divisão congelada. A referência constante superar o Random Forest em MAE e a subestimação integral acima do P95 impedem uma conclusão de bom desempenho geral. A análise de atributos da skill permanece parcial, pois a comparação com texto foi interna e restrita ao Ridge.

5 Discussão

5.1 Desempenho e características dos dados

Os resultados mostram sinal preditivo, mas com alcance limitado. A representação híbrida teve o menor RMSLE médio do Ridge na validação interna; a diferença de 0,004 para `skill-only` é pequena diante do desvio-padrão entre dobras (0,028 e 0,031). O experimento sugere informação nos atributos da skill, mas não demonstra superioridade robusta do híbrido nem desempenho externo de um modelo textual. A maior correlação de Spearman de `repository-only` reforça que as métricas capturam aspectos diferentes.

A assimetria e a sobredispersão do alvo ajudam a explicar o comportamento. A

maioria das skills reutilizadas aparece em poucos repositórios, enquanto uma parcela pequena concentra contagens elevadas. A referência constante teve MAE externo menor que o Random Forest (3,067 contra 3,266), embora RMSLE pior (0,714 contra 0,583). Portanto, o ganho do modelo depende da métrica escolhida. Acima do P95 do treino, o Random Forest subestimou todas as 324 observações externas, com MAE de 35,15.

5.2 Comparação dos modelos e vieses indutivos

O benchmark completo foi realizado na visão `repository-only`. O Random Forest foi escolhido como candidato principal pelo menor RMSLE da validação agrupada (0,5753). No teste externo, obteve 0,5833; o Gradient Boosting obteve 0,5907, mas MAE menor (3,1820 contra 3,2663). Esses valores externos avaliam candidatos já congelados e não são uma nova rodada de seleção. A variação entre três dobras e a única divisão externa limitam a precisão de comparações pequenas.

O Ridge impõe uma relação aditiva e regularizada, sendo estável e relativamente fácil de interpretar, mas tende a encolher valores extremos. KNN depende da geometria local dos atributos e teve o pior RMSLE do benchmark completo. A árvore de decisão isolada não superou os ensembles e apresentou maior variabilidade. Random Forest e Gradient Boosting capturam não linearidades e interações, mas podem explorar sinais contextuais que não generalizam para outros ecossistemas.

5.3 Explicabilidade e interpretação

As análises textuais exploratórias identificaram termos editoriais e sinais de templates; a robustez ao mascaramento não mostra que sejam propriedades causais da skill. No Random Forest `repository-only`, a importância por impureza destacou `repo_stars`, `history_fetched`, ausência de `commit_count` e `repo_forks`. Já a permutação agrupada colocou `repo_language` em primeiro (aumento médio de RMSLE 0,029), seguido por `commit_count` (0,014), `history_fetched` (0,013) e `repo_stars` (0,012). A divergência decorre em parte das propriedades das medidas de importância e da correlação entre atributos; o sinal de estrelas variou substancialmente entre dobras.

No cenário que varia estrelas mantendo as outras entradas, a previsão média foi não monotônica. Isso enfraquece uma regra simples sobre popularidade e reutilização, embora o cenário não seja uma estimativa causal e possa criar combinações raras de atributos. O uso de `repo_language` e histórico também pode codificar origem, cobertura da coleta ou práticas de distribuição. A interpretação do Random Forest é apenas contextual; não identifica variáveis textuais ou estruturais da skill como determinantes da reutilização.

5.4 Implicações para a engenharia de software

O pipeline pode apoiar análises exploratórias de autoria e descoberta, indicando convenções que merecem inspeção ou priorizando skills para auditoria manual. Ele ainda não justifica um linter automático, um ranking de qualidade ou uma intervenção de autoria. Essas aplicações exigiriam validação prospectiva, avaliação de utilidade e controle de pos-

síveis efeitos adversos, como reforçar padrões de popularidade ou favorecer determinados ecossistemas.

Para o trabalho, a contribuição principal é metodológica: comparar modelos sob a mesma divisão agrupada, relacionar desempenho a vieses indutivos e demonstrar que métricas agregadas podem ocultar erros graves na cauda. Os resultados também delimitam o que pode ser inferido de uma medida observacional de replicação exata.

5.5 Ameaças à validade e limitações

`repository_count` mede a presença de conteúdo idêntico em repositórios distintos. Não mede intenção de adoção, uso efetivo, qualidade, utilidade, sucesso de execução ou transferência de conhecimento. Cópias modificadas e equivalentes semânticos não são capturados.

O agrupamento por `representative_repo_id` elimina a sobreposição desse identificador entre treino e validação, mas não garante que todos os repositórios relacionados, organizações ou cadeias de cópia estejam separados. Metadados de repositório também podem funcionar como proxies de popularidade ou origem.

O RMSLE reduz a influência de valores extremos, mas pode ocultar erros absolutos elevados. Por isso, a análise também utiliza MAE, Spearman, uma referência constante e auditoria por quantis. A subestimação acima do P95 mostra que nenhuma métrica isolada caracteriza adequadamente o desempenho. A comparação textual foi avaliada apenas com Ridge dentro do desenvolvimento; não autoriza afirmar que o modelo final explica características intrínsecas da skill.

Os dados provêm de um snapshot específico do GitHub e de um ecossistema particular de Agent Skills. A generalização para outros períodos, hosts, comunidades ou mecanismos de distribuição não é garantida. A avaliação externa reportada é válida para a divisão adotada neste estudo e não substitui replicações em outros snapshots ou ecossistemas.

6 Conclusão e trabalhos futuros

Este trabalho desenvolveu um pipeline reprodutível para investigar a intensidade de reutilização de Agent Skills como artefatos de engenharia de software. A pesquisa modelou o número de repositórios que contêm exatamente o mesmo `SKILL.md`, condicionando a análise às skills reutilizadas. O protocolo combinou atributos estruturais, sinais textuais e contexto de repositório, utilizou validação agrupada por `representative_repo_id` e realizou a seleção de atributos dentro das dobras.

Seis regressores foram comparados sobre 25.918 skills reutilizadas na visão `repository-only`. O Random Forest foi escolhido pelo menor RMSLE médio na validação agrupada (0,5753) e obteve 0,5833 no teste externo de 6.479 skills. O Gradient Boosting teve MAE externo menor (3,1820 contra 3,2663). Uma referência constante baseada na mediana do desenvolvimento teve RMSLE pior (0,7142), mas MAE melhor (3,0665) que o Random Forest. A escolha do modelo depende, portanto, do objetivo e da métrica.

A previsão da reutilização é parcial. O Random Forest subestimou todas as 324 skills do teste acima do P95 do desenvolvimento e teve MAE de 35,15 nessa faixa. O Ridge híbrido apresentou falha semelhante na validação interna, em análise separada. A comparação das três representações com Ridge sugere sinal em texto e estrutura, mas a diferença entre `hybrid` e `skill-only` é pequena diante da variação entre dobras e ainda não foi testada externamente. As importâncias por permutação do Random Forest se referem a contexto de repositório, não a propriedades intrínsecas da skill.

Concluímos que características observáveis permitem prever parte da intensidade de replicação exata entre repositórios, sobretudo na região central. A evidência não permite explicar por que uma skill se dissemina, inferir qualidade ou formular uma regra para torná-la mais reutilizável.

Estudos futuros podem avaliar as representações textuais em um novo teste externo ainda não consultado, comparar outras estratégias para a cauda e validar hipóteses em outros snapshots ou ecossistemas. O presente relatório documenta os resultados e os limites do protocolo executado.

Referências

[Agent Skills] Agent Skills. Specification – agent skills. `https://agentskills.io/specification`. Accessed: 2026-10-27.

[Breiman 2001] Breiman, L. (2001). Statistical modeling: The two cultures (with comments and a rejoinder by the author). *Statistical Science*, 16(3):199–231.

[Destefanis et al. 2027] Destefanis, G., Graziotin, D., Vaccargiu, M., and Ortu, M. (2027). GitSkills: A dataset of agent skills on GitHub. In *Proceedings of the 24th IEEE/ACM International Conference on Mining Software Repositories (MSR)*.

[Geirhos et al. 2020] Geirhos, R., Jacobsen, J.-H., Michaelis, C., Zemel, R., Brendel, W., Bethge, M., and Wichmann, F. A. (2020). Shortcut learning in deep neural networks. *Nature Machine Intelligence*, 2(11):665–673.

[Haefliger et al. 2008] Haefliger, S., Von Krogh, G., and Spaeth, S. (2008). Code reuse in open source software. *Management Science*, 54(1):180–193.

[Han et al. 2026] Han, T., Zhang, Y., Song, W., Fang, C., Chen, Z., Sun, Y., and Hu, L. (2026). SWE-Skills-Bench: Do agent skills actually help in real-world software engineering? *arXiv preprint arXiv:2603.15401*.

[Heinemann et al. 2011] Heinemann, L., Deissenboeck, F., Dreier, M., Göde, N., Hummel, B., and Jürgens, E. (2011). On the extents, origins, and problems of software reuse in open source software. In *Proceedings of the 14th International Conference on Fundamental Approaches to Software Engineering (FASE)*, pages 258–272. Springer.

[Kaufman et al. 2012] Kaufman, S., Rosset, S., Perlich, C., and Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data (TKDD)*, 6(4):1–21.

[Lapuschkin et al. 2019] Lapuschkin, S., Wäldchen, S., Binder, A., Montavon, G., Samek, W., and Müller, K.-R. (2019). Unmasking Clever Hans predictors and assessing what

machines really learn. *Nature Communications*, 10(1):1096.

[Lopes et al. 2017] Lopes, C. V., Maj, P., Martins, P., Sajnani, V., Di Rocco, J., Summer, H., and Baldi, P. (2017). Déjàvu: a map of code duplicates on GitHub. *Proceedings of the ACM on Programming Languages*, 1:1–28.

[Menzies et al. 2010] Menzies, T., Milton, Z., Turhan, B., Cukic, B., Jiang, Y., and Bener, A. (2010). Defect prediction from static code features: current results, limitations, new approaches. *Automated Software Engineering*, 17(4):375–407.

[Mockus et al. 2002] Mockus, A., Fielding, R. T., and Herbsleb, J. D. (2002). Two case studies of open source software development: Apache and Mozilla. *ACM Transactions on Software Engineering and Methodology (TOSEM)*, 11(3):309–346.

[Molnar 2020] Molnar, C. (2020). *Interpretable machine learning: A guide for making black box models explainable*. Independently published.

[OpenAI 2026] OpenAI (2026). Codex: Ai coding agent. `https://openai.com/codex/`. Accessed: 2026-10-27.

[Qin et al. 2023] Qin, Y., Liang, S., Ye, Y., Zhu, K., Yan, L., Lu, Y., Lin, Y., Cong, X., Tang, X., Qian, B., et al. (2023). Toolllm: Facilitating large language models to master 16000+ real-world apis. *arXiv preprint arXiv:2307.16789*.

[Roberts et al. 2017] Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., et al. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8):913–929.

[Saeb et al. 2017] Saeb, S., Lonini, L., Jayaraman, A., Mohr, D. C., and Kording, K. P. (2017). The need to separate related samples in cross-validation: Error estimation for models that predict cross-subject traits. *GigaScience*, 6(4):gix019.

[Schick et al. 2023] Schick, T., Dwivedi-Yu, J., Dessì, R., Raileanu, R., Lomeli, M., Zettlemoyer, L., Cancedda, N., and Scialom, T. (2023). Toolformer: Language models can teach themselves to use tools. *Advances in Neural Information Processing Systems*, 36:68539–68551.

[Shen et al. 2023] Shen, Y., Song, K., Tan, X., Li, D., Lu, W., and Zhuang, Y. (2023). Hugginggpt: Solving ai tasks with chatgpt and its friends in hugging face. *Advances in Neural Information Processing Systems*, 36:37819–37834.

[Shmueli 2010] Shmueli, G. (2010). To explain or to predict? *Statistical Science*, 25(3):289–310.

[Tafreshipour et al. 2025] Tafreshipour, M., Imani, A., Huang, E., de Almeida, E. S., Zimmermann, T., and Ahmed, I. (2025). Prompting in the wild: An empirical study of prompt evolution in software repositories. In *Proceedings of the 22nd IEEE/ACM International Conference on Mining Software Repositories (MSR)*.

[Yao et al. 2023] Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., and Cao, Y. (2023). React: Synergizing reasoning and acting in language models. In *International Conference on Learning Representations (ICLR)*.

[Zhang et al. 2026] Zhang, C., Liu, Y., Chen, X., and Ji, P. (2026). What keeps agent skills from being reusable? evidence from 138k SKILL.md files. *arXiv preprint ar-*

Xiv:2608.08453.

A Reprodutibilidade e execução

A.1 Dados e ambiente

Fonte pública: GitSkills no Hugging Face, revisão fixa `ebab17454a7c236f8f26b183567f1a126f42e3f8` (snapshot registrado como julho de 2026). O download usa `artifacts` e `repos` e verifica SHA-256. A agregação calcula `repository_count` por `file_sha` usando `COUNT(DISTINCT repo_full_name)` antes da amostragem. Os 200.000 conteúdos são os primeiros na ordenação `md5(content_hash || ':20261009'), content_hash` da população. A divisão externa agrupada por `representative_repo_id` produz 160.000 conteúdos de desenvolvimento e 40.000 de teste; entre os conteúdos reutilizados (`repository_count >= 2`), restam 25.918 e 6.479 linhas. Essa é uma amostra determinística, não uma amostra aleatória simples com erro amostral conhecido.

O ambiente usa Python 3.12, `pyproject.toml` e `uv.lock`. A amostragem usa semente `20261009`; os experimentos usam semente `2027` e três dobras `StratifiedGroupKFold`. Os comandos abaixo partem da raiz do repositório.

A.2 Construção dos dados

```
uv sync
uv run skillreuse-download-full
uv run skillreuse-build-full
uv run skillreuse-build-final-features
uv run skillreuse-prepare-count-target
```

As entradas resultantes são `data/processed/final_modeling_sample.parquet`, `final_structured_features.parquet` e `final_targets.parquet`. Versões, cardinalidades e partições estão em `reports/tables/full_population_manifest.json` `reports/tables/final_feature_manifest.json` e `reports/modeling/count_regression/count_target_manifest.json`.

A.3 Validação e avaliação

Comparação Ridge das três representações:

```
uv run skillreuse-benchmark-count --candidate-features 10000 --top-k 50
  --views skill_only repository_only hybrid --models ridge_log --folds
  --output-dir reports/modeling/count_regression/selected_full_ridge
```

Comparação dos seis regressores sobre os atributos de repositório:

```
uv run skillreuse-benchmark-discipline --views repository_only --folds
  --output-dir reports/modeling/discipline_benchmark/full_repository_on
```

O spot-check está em `reports/modeling/discipline_benchmark/spot_check_rep`
A avaliação externa abaixo **já foi executada**; repetir para verificar reprodutibilidade não autoriza novo ajuste pelos resultados:

```
uv run skillreuse-evaluate-discipline \
  --output-dir reports/modeling/discipline_benchmark/final_repository_o
```

As tabelas da Seção 4 derivam de `selected_full_ridge/count_regression_pilot_s`
`full_repository_only_20261109/regression_summary.csv`,
`spot_check_repository_only_20261109/spot_check_summary.csv`
e `final_repository_only/test_summary.csv`.
`random_forest_test_predictions.csv` contém as previsões externas usadas na auditoria.

A.4 Figuras e auditoria

```
uv run python -m gitskills_reuse.analysis.discipline_report
```

O comando gera quantis e valores ausentes do desenvolvimento, referência constante calculada pela mediana do desenvolvimento, métricas por faixa das previsões externas salvas e gráficos em `reports/modeling/discipline_benchmark/report_audit/`. A importância por permutação e o cenário de estrelas são recalculados **apenas no desenvolvimento** com três dobras agrupadas. `audit_manifest.json` registra fontes, sementes, cortes e limites. A auditoria separada do Ridge híbrido está em `reports/modeling/count_regression/tail_audit/`.

A.5 Verificações

```
uv run pytest -q tests/test_count_targets.py tests/test_preprocess.py
```

Os testes verificam a construção do alvo e a exclusão de colunas de vazamento. A reprodução integral deve conferir os manifestos de divisão, a ausência de grupos compartilhados e a correspondência entre CSVs e tabelas do relatório. Arquivos históricos de modelos fora do escopo da entrega não integram as comparações apresentadas.

B Uso de ferramentas de inteligência artificial

OpenAI Codex [OpenAI 2026] foi utilizado para planejar o pipeline, auxiliar na implementação e depuração do código, organizar e revisar o texto e conferir a consistência entre tabelas e resultados. O autor definiu os alvos e as restrições da pesquisa, examinou os artefatos produzidos e é responsável pelo código, pelas afirmações e pela interpretação final. A ferramenta deve ser citada na versão formatada do artigo conforme a orientação da disciplina.

O `registro de uso` resume as tarefas, mas não preserva todos os prompts e respostas integrais. O `suplemento de IA` contém cinco prompts verbatim disponíveis no histórico, incluindo o pedido desta revisão, e explicita a incompletude do registro. Não foram inventados prompts de sessões de implementação ausentes. Erros relevantes de assistência incluíram risco de transportar conclusões do pipeline binário para a regressão, confundir associação com causalidade e tratar a avaliação externa como seleção. As afirmações quantitativas deste relatório foram reconciliadas com os CSVs e manifestos mencionados no Apêndice A; a bibliografia ainda requer conferência editorial final antes da submissão.